

卒業論文

環境エネルギー駆動型センサノードの Q 学習による電力制御

研究指導：内田 健康 教授

早稲田大学 先進理工学部 電気・情報生命工学科 内田研究室

1Y15F148-5 吉竹 孝明

提出日:2019年2月10日

目 次

1	はじめに	2
2	センサシステムのモデル化	3
2.1	システムの概要	3
2.2	システムの制御方法	4
3	Q 学習を用いたセンサシステムの制御	4
3.1	Q 学習	4
3.2	Q 学習のセンサシステムへの適用	5
3.2.1	状態, 行動の集合	5
3.2.2	報酬関数の設定	6
3.2.3	学習アルゴリズム	6
4	Q 学習を用いたシミュレーションとその評価	7
4.1	シミュレーション設定	7
4.2	行動選択手法の比較	7
4.3	学習データ数による利用結果の変化	8
4.4	日射量予測データの利用	10
4.5	日射量への適応性	10
5	まとめ	13

1 はじめに

近年、膨大な数のセンサノードが生活空間の中に設置され、様々な情報を得ることで我々の生活を豊かにする Internet of Things (IoT) が発展しつつある。そこで用いられるセンサノードは、高い信頼性と持続性が求められる。特に無線通信を行うワイヤレスセンサノードにおいて、エネルギーの供給は重要な問題である。一次電池駆動型のセンサノードでは、省電力化により一次電池による駆動期間を伸ばすことが可能になるが、それでも駆動期間は限られる。そのため、バッテリー交換や再充電などのメンテナンスが必要になり、保守にコストがかかってしまう。

そこで、環境から得られるエネルギーで駆動するセンサノードが注目されている [1]。代表的な発電環境としては、振動発電、太陽光発電、温度差発電などが挙げられる。このセンサノードは、バッテリーのメンテナンスに関して人手がかからないため、設置場所の制約によらず持続的にセンサを運用することが期待できる。発電環境は常に不安定であるため、わずかな発電量でも機能できる緩やかな状態の変化を測定する場面で有用である。具体的な用途例としては、生活空間の中の温度・湿度センサや、土壌中の成分を測定する目的で農業などに用いられる [2]。この環境エネルギー駆動型のセンサノードでは、エネルギー消費の省電力化ではなく、環境から得られるエネルギーを用いて、バッテリー切れや余剰エネルギーの廃棄を防ぎつついかに高い性能を発揮させることができるかを目的とする。

環境エネルギー駆動型のセンサノードでは、発電電力は時間により変動するため、電力の安定供給が難しいという側面を持つ。そのため、様々な状況において、バッテリー切れや余剰エネルギーの廃棄を防ぐことは簡単なことではない。そこで、本研究では、センサノードのデューティ比を調整する問題へと帰着させて議論する。ただし、デューティ比は直接報酬関数で評価せず、バッテリー残量に依存する報酬関数を用いる。つまり、最も報酬が得られるバッテリー残量になるように、デューティ比を調整する。

また、環境エネルギー駆動型の電力制御の手法として、Q 学習を用いる。Q 学習とは強化学習の一種で、最適な行動を学習するための理論的な枠組みである。学習器が一連の行動によりもたらされる結果と報酬を記録していき、実行段階でより最適な行動を状況に応じて選択できるようにするものである。

本研究では、Q 学習を利用してデューティ比を調整し、バッテリー運用を行う手法を提案する。また、環境から得られるエネルギーとして太陽光発電を利用したセンサノードを仮定する。Q 学習を用いたデューティ比最適化手法としては、文献 [3] の手法をベースにする。また、未来の日射量データを予測して、バッテリー運用をより向上させる手法も提案する。

本論文の構成は以下のとおりである。2 章では、本論文で扱う環境エネルギー駆動型のセンサシステムのモデル化について述べ、3 章では、Q 学習を用いたセンサシステムの制御について述べ、4 章では、Q 学習を用いたシミュレーションとその評価、5 章では、まとめと今後の課題について述べる。

2 センサシステムのモデル化

2.1 システムの概要

本研究では，環境エネルギー駆動型のセンサノードのシステムモデルとして，エネルギー源となる太陽光パネル，バッテリー，センサノード，電力管理ユニットの4つからなるモデルを検討する．システムモデルの概略図を図2.1に示す．デューティ比とは，ある期間における実際に稼働している時間の割合を表し，センサノードのデューティ比は電力管理ユニットから指定され，変化させることができる．デューティ比が高いほど，ある期間における稼働時間が長くなるため，センサノードの性能は高くなる．時間は離散時間のモデルを仮定し，等区間に分割して考える．各離散時間 t_k において，システムは太陽光パネルからエネルギー $e_{harvest}(t_k)$ を取得する．電力管理ユニットは，センサノードに対してデューティ比 $d(t_k)$ を決定する．センサノードは，電力管理ユニットにより決定された $d(t_k)$ に応じてエネルギー $e_{node}(t_k)$ を消費する．システムには容量 B_{full} のバッテリーが接続され，エネルギーを蓄えることができる． $e_{battery}(t_k)$ は各離散時間 t_k の開始時点でのバッテリー残量とする．

バッテリー残量は，以下の式で更新される．

$$e_{battery}(t_{k+1}) = e_{battery}(t_k) + e_{harvest}(t_k) - e_{node}(t_k) \quad (2.1)$$

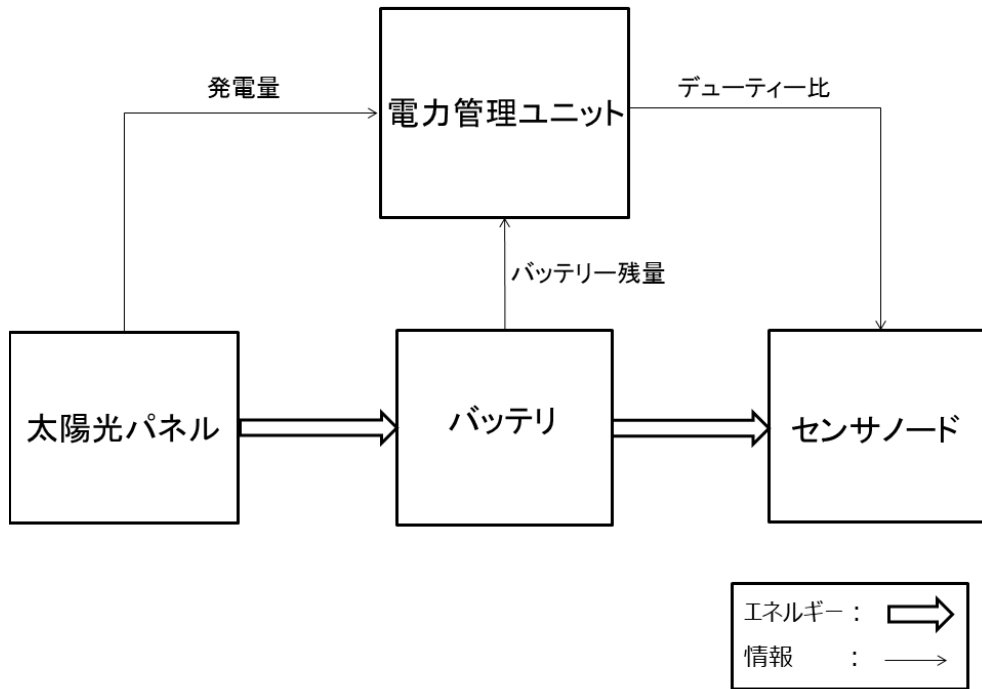


図 2.1: システムモデル

2.2 システムの制御方法

先ほど述べたシステムモデルにおいて、電力管理ユニットが学習器を持つ。学習器を用いてデューティ比を制御し、センサノードでのエネルギー消費量を制御することでバッテリー残量の最適化を行う。学習器に関しては、次章で説明する。

3 Q 学習を用いたセンサシステムの制御

3.1 Q 学習

Q 学習とは、強化学習の一種である。強化学習とは、未知の情報に対しても、学習を進めながら自力で行動を最適化していく理論である。主体はエージェントと呼ばれ、行動をとる。また、行動は環境と呼ばれる対象に対してはたらきかける。行動は $a \in A$ で表し、行動をとることで変化していく環境を状態 $s \in S$ とする。強化学習では、ある状態における、エージェントが環境に対してはたらきかけた行動の結果の指標として、報酬 $r \in R$ で行動の良さを評価する。強化学習問題を解くということは、エージェントが置かれている環境の中で、行動を選択していく道のりで得られる報酬の総和を最大化することである。

エージェントと環境の相互作用は離散時間単位で行われ、ある離散時間単位 k では、エージェントは状態 s_k を持ち、ある方策に基づいて行動 a_k を行う。この行動の決定により、状態は遷移し、次の状態 s_{k+1} が定まる。そして、次の状態に応じて報酬 r_{k+1} が定まる。

強化学習問題を解くということは、できるだけ多くの報酬を受け取れるように、エージェントが行動を決定するためのルールである方策を設計するということである。つまり、エージェントが行動を通して環境にはたらきかけ、その結果を報酬と状態という形で観測することにより、方策を改善していくことが求められる。

Q 学習では、Q 値と呼ばれる行動価値関数 $Q(s, a)$ を用いる。行動価値関数 $Q(s, a)$ は状態 s と行動 a により定義され、 $(s \times a)$ の Q テーブルを構築する。ある状態と行動のペア (s, a) の Q 値は、状態 s からスタートして行動 a を選択した時に得られる報酬の和の最大値と定義され、Q テーブルに保存される。学習が進むにつれて Q テーブルは更新され、各状態において価値のある行動が Q 値の大きさによって評価されていく。Q 学習とは、プロセスを経て各状態と行動のペアにおける Q 値を収束させることである。すべての状態と行動のペアにおいて Q 値が収束していれば、各状態において最も高い Q 値を持つ状態へと遷移できるような行動をとればよい。なお、Q 値の更新は以下の式に基づいて行われる。

$$Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \{ r_k + \gamma \max_{a'} Q(s_{k+1}, a') - Q(s_k, a_k) \} \quad (3.1)$$

a' は、遷移先の状態 s_{k+1} で最大の Q 値をとる際の行動を表している。 α は学習率 ($0 < \alpha \leq 1$) で、 γ は割引率 ($0 < \gamma \leq 1$) と呼ばれる。学習率が大きければ大きいほど今までの推定値から大きく更新し、小さくなるにつれて推定値からの更新が小さくなる。また、割引率は、将来的に得られるであろう報酬和の、現時点での重要度を表している。割引率が 1 に近ければ、より長期的に有益な行動をとるようになり、割引率が 0 に近ければ、より即時的に有益な行動をとるようになる。

また、行動を選択する手法として greedy 法と ϵ -greedy 法がある。greedy 法とは、これまでの結果から期待値が最大となるものを選ぶアルゴリズムで、エージェントが現在の Q テーブルをもとにして、 Q 値が最大になるものを選ぶ。ある程度情報を収集して Q 値が収束してから適用することで、greedy アルゴリズムによって最適な行動を選ぶことができる。しかし、greedy アルゴリズムでは最適解を誤認した際に、いつまでも修正することができないというリスクが生じる。これを解消する単純な方法として用いられるのが、 ϵ -greedy 法である。これは、確率 ϵ ですべての行動からランダムに行動を選ぶことで、他の行動の価値を探索するというものである。これによりすべての行動が十分な回数試されることになり、期待値の誤差は 0 に収束し、リスクを減らすことができる。また、確率 ϵ でランダムな行動を選び続けることから、探索コストは ϵ に比例することになるので、試行回数に応じて ϵ を少しずつ減らしていくことで探索コストを削減できる。よりコストをかけて最適解の探索を行えばリスクを減らすことはできるが、無限にコストをかけてもリスクをゼロにすることはできない。これを、探索と利用のトレードオフと呼ぶ。

3.2 Q 学習のセンサシステムへの適用

ここでは、強化学習モデルで用いる状態と行動の集合について定義する。本モデルでは、環境はバッテリー残量と発電エネルギーから構成され、環境はエージェントに対して行動に応じた報酬を与え、発電エネルギー量とバッテリー残量に応じて新たな状態を指定する。状態と行動の集合の定義、および報酬について以下に定義する。

3.2.1 状態、行動の集合

状態の集合 S は、バッテリー残量の状態 $S_{battery}$ 、一つ前の離散時間における発電エネルギー量の状態 $S_{harvest}$ からなる。よって、状態は $S_{battery}$ と $S_{harvest}$ の組み合わせ $(S_{battery}, S_{harvest}) \in S$ で与えられる。行動の集合 A は、設定可能なデューティ比の集合 $A \in \{D_{min}, D_{max}\}$ で定義される。なお、 D_{min} と D_{max} はそれぞれ、対称のセンサノードで設定可能なデューティ比の最小値及び最大値を表す。エージェントは各離散時間において、1つのデューティ比を設定できる。

3.2.2 報酬関数の設定

報酬関数とは、振る舞いに応じて変化する報酬を定めるものであり、本研究では、バッテリー残量に依存した以下の式で表される報酬関数を用いた。

$$r = b_6 \times S_{batt}^6 - b_5 \times S_{batt}^5 + b_4 \times S_{batt}^4 - b_3 \times S_{batt}^3 + b_2 \times S_{batt}^2 - b_1 \times S_{batt} - b_0$$

$$b_6 = 5.82 \times 10^{-9}$$

$$b_5 = 1.52 \times 10^{-6}$$

$$b_4 = 1.34 \times 10^{-4}$$

$$b_3 = 4.91 \times 10^{-3}$$

$$b_2 = 9.39 \times 10^{-2}$$

$$b_1 = 0.305$$

$$b_0 = 0.111$$

ここで、 S_{batt} はバッテリー残量のパーセンテージ表記を表す。上記の報酬関数をグラフで表すと次のようになる。




図 3.1: 報酬関数

報酬関数は6次関数で表され、バッテリー残量約70%で最大の報酬が与えられるように設定した。また、バッテリー残量が20%未満の際は、発電量とデューティ比によってはバッテリー残量が0になりうるので危険域として扱う。

3.2.3 学習アルゴリズム

本研究では、各状態と行動のペアにおける Q 値を決定させるために、先ほど述べた Q 学習を用いる。学習フェーズでは、様々なパターンで状態が遷移し、よりよい報酬を得るために Q 値を更新しつつ探索的に行動する。また、過去の気象データを用いて十分に Q 値が収束するまで ϵ -greedy 法を用いて学習を行い、 Q 値が十

分収束したところでセンサノードを配置し, greedy 法にもとづいて行動を選択していく.

4 Q 学習を用いたシミュレーションとその評価

4.1 シミュレーション設定

以下に, シミュレーションを行うにあたってシステムに与えた設定を述べる.

本研究では, 太陽光パネルが付属したセンサノードを仮定し, 気象庁のウェブサイト [4] より東京地点での時間当たりの全天日射量データを取得して, 発電エネルギー量に換算し用いる. 日射量データに合わせて, 離散時間は 1 時間として評価を行う. 以下に, 全天日射量を発電エネルギー量に変換させる式を示す. なお, 時次発電量を $E_p[mWh]$, 全天日射量を $H[MJ]$, 欠損係数を K , 太陽光発電容量を $P[MWh]$ とする.

$$E_p = H \times \frac{10^6}{3.6} \times K \times P \quad (4.1)$$

なお, 本シミュレーションでは欠損係数 $K=0.85$, 太陽光発電容量 $P=2.25 \times 10^{-3}[mWh]$ と仮定する. また, 発電量の最大値, 最小値に関しては, $e_{maxh}=3000mWh$, $e_{minh}=0mWh$ とする.

センサノードは, 電力管理ユニットから指定されたデューティ比に応じて離散時間あたりに 50mW から 500mW のエネルギーを消費すると仮定する. なお, デューティ比は 10 % 刻みで設定可能とした. 1 時間のうちのセンサノードの消費電力の変動はないものとする. また, デューティ比の変更に伴うレイテンシなどのオーバーヘッドは無視できると仮定する.

バッテリーとしては, 容量 20000mWh のバッテリーを仮定し, 漏れ電流や時間の経過による劣化は考慮しない理想的な特性を持っていると仮定する.

システムの状態は $S \in \{S_{battery}, S_{harvest}\}$ で定義され, それぞれ $S_{battery} \in \{1, 2, \dots, 85\}$, $S_{harvest} \in \{1, 2, \dots, 5\}$ とする. バッテリーは容量 20000mWh を 85 等分で表し, 発電エネルギー量は 3000mWh を 5 等分で表す.

行動の集合は, $A \in \{10, 20, \dots, 100\}$ で定義され, パーセンテージ表記のデューティ比を表している. 各離散時間において電力管理ユニットよりデューティ比が指定される.

報酬は, 各離散時間におけるバッテリー残量をパーセンテージ表記である S_{batt} に変換したものを先ほど示した報酬関数に入力して得られる.

4.2 行動選択手法の比較

ここでは, 2003 年から東京地点の日射量データ 10 年分で greedy 法と ϵ -greedy 法それぞれ用いて学習し, 2017 年に適用させた結果を図 4.1, 図 4.2 に示す.




図 4.1: greedy 法で学習




図 4.2: ϵ -greedy 法で学習

図 4.1 と図 4.2 を比較すると，greedy 法で学習した結果を利用したグラフは一部バッテリー残量が 0 に近づいているが， ϵ -greedy 法で学習した結果を利用したグラフは一定のバッテリー残量を保つことができていることが分かる．greedy 法は，学習した Q テーブルをもとにして， Q 値が最大になるものを選ぶアルゴリズムである．greedy 法の欠点として，最適解を誤認した際に，いつまでも修正できないリスクが存在するが， ϵ -greedy 法は確率 ϵ でランダムな行動を選ぶことにより誤った最適解に陥るリスクを減らすことができる．図 4.1 のバッテリー残量低下は，最適解を誤認してしまった結果危険域まで低下してしまったと考えられる．また，確率 ϵ でランダムな行動を選ぶこと自体がコストになってしまうが，試行回数が増えていくにつれて確率 ϵ を小さくしていくことでコストも削減することができるため，グラフの結果も含めて greedy 法よりも ϵ -greedy 法を用いたほうが有用であると判断できる．これ以降の結果では， ϵ -greedy 法を用いて学習し，適用させる際は greedy 法を用いる．

4.3 学習データ数による利用結果の変化

ここでは，学習に用いるデータ数の違いによるシミュレーション結果を考察する．東京地点の 2003 年から 1 年分，10 年分，15 年分の日射量データを用いて学習し，greedy 法に従って東京地点の 2017 年のデータを利用して評価した結果をそれぞれ図 4.3，図 4.4，図 4.5 に示す．




図 4.3: 1 年分のデータの学習利用結果





図 4.4: 10 年分のデータの学習利用結果 図 4.5: 15 年分のデータの学習利用結果

各グラフは、大きな特徴が表れる 12 日間の観測結果を切り取ったもので、横軸は離散時間、縦軸はバッテリー残量及び発電量のパーセンテージ表記を表している。図 4.3 と図 4.4 を比較してみると、図 4.3 はバッテリー残量が 0 に近づいているのに対し、図 4.4 では、バッテリー残量を十分に保つことができていていることが分かる。図 4.3 では発電量に応じて適切にデューティ比を変動させることができなかったため、バッテリー残量が危険域あるいは 0 になってしまっていると考えられる。それに比べて図 4.3 では、バッテリー残量に応じてデューティ比を適切に変更させることでバッテリー残量を十分に保つことができていている。また、図 4.4 と図 4.5 で比較してみると、どちらもバッテリー残量を十分に確保できていて、図 4.5 の方がわずかにバッテリー残量が多い。よって、どちらも適切にセンサノードのバッテリー残量を制御できていて、学習年数の多い図 4.5 がわずかにより良い結果となったことが確認できる。図 4.3 と図 4.4 及び図 4.5 でバッテリー制御に差が出た原因としては、1 年分のデータでは Q テーブルの各 Q 値の収束が不十分であったためだと考えられる。バッテリー残量の分割数が 85、発電量の分割数が 5 で、それぞれの状態に対して 10 通りの行動が考えられるので、4250 通りの状態と行動のペアに対して Q 値を割り当てることになる。これらの結果より、1 年分のデータで約 8760 回、10 年分のデータで約 87600 回の学習総試行回数となるので、これらの Q 値を収束させるには、10 年分の日射量データがあれば十分であると考えられる。

4.4 日射量予測データの利用

ここでは、一つ前の離散時間における日射量データを状態として扱った場合と、3 時間後までの発電量の平均値を状態として扱った場合のバッテリー運用について比較する。なお、未来の日射量データに関しては常に正しく予測できると仮定する。図 4.6 に、バッテリー残量の推移の比較を示す。




図 4.6: バッテリー残量の比較

グラフより、黒線で示されている 3 時間後までの平均の発電量を利用した場合の方がバッテリー残量が上回っていることが分かる。これは、未来の日射量データを予測することで、のちに十分に発電量が得られない場合でも早めにデューティ比を抑えることで、バッテリー残量の急激な低下を回避することができたためだと考えられる。以上より、一つ前の離散時間における日射量データを現在の発電量の状態として扱うより、3 時間後の発電量の平均値を状態として扱った方が有用であると考えられる。また、これ以降の結果は 3 時間後の発電量の平均値を状態として扱っている。

4.5 日射量への適応性

ここでは、日射量の多い時期と少ない時期での発電エネルギー量の違いに適応できているか考察する。学習は 1 年を通じて行われるため、極端に日射量が多い、または少ない時期に学習結果を適用させたときにも適応できるかどうかは重要な問題となる。先ほどと同じ条件で 10 年分学習させた Q テーブルを用いて、日射量が多い時期と少ない時期でそれぞれ利用させた結果を図 4.7, 図 4.8 に示す。





図 4.7: 日射量が多い時期での利用結果 図 4.8: 日射量が少ない時期での利用結果

図 4.7 は、夏季の約 7 日間のデータを抜き取ったもので、図 4.8 は冬季の約 7 日間を抜き取ったものである。図 4.7 では、全天日射量が平均的に多い、つまり発電エネルギー量が多いため、バッテリー残量にも余裕があり、比較的に高いデューティ比を用いていることがわかる。また、発電が少ない夜間においても高いデューティ比での駆動が達成できていることが確認できる。しかし、一部バッテリー残量が 100 % に達してしまい、発電の余剰エネルギーを廃棄してしまっていることが分かる。図 4.8 では、全天日射量が平均的に少ないため、バッテリー残量に応じてデューティ比を変動させて残量を保っている。しかし、夏に比べると十分なバッテリー残量は保つことはできていない。

次に、3 月～8 月を日射量が多い月、9 月～2 月を日射量が少ない月として 1 年のうちの 12 か月を 2 つに分類し、総試行回数が 10 年分になるように学習させた 2 つの Q テーブルを日射量が多い時期と少ない時期に適用させたときの 1 週間の結果を示す。なお、比較するために前節で用いた図と並べて示す。まず、1 月～12 月の日射量データで学習させた Q テーブルを日射量が多い時期に適用させた結果を図 4.9 に、3 月～8 月の日射量データで学習させた Q テーブルを日射量が多い時期に適用させた結果を図 4.10 に示す。




図 4.9: 1～12 月の日射量で学習




図 4.10: 3～8 月の日射量で学習

図 4.9 と図 4.10 のグラフを比較すると、バッテリー残量に関しては大きな差は無いが、デューティ比に関してはわずかながら図 4.10 の方が高くなっていることが分

かる。しかし、やはり一部余剰な発電エネルギーを廃棄してしまっている。

次に、1月～12月の日射量データで学習させたQテーブルを日射量が少ない時期に適用させた結果を図4.11に、9月～2月の日射量データで学習させたQテーブルを日射量が少ない時期に適用させた結果を図4.12に示す。




図 4.11: 1～12月の日射量で学習




図 4.12: 2～9月の日射量で学習

図4.11と図4.12のグラフを比較すると、バッテリー残量は1～12月の日射量データで学習した結果を適用させたグラフよりも2～9月の日射量データで学習した結果を適用させたグラフの方が高い割合を保つことができています。

次に、1～12月の日射量データで学習した結果を日射量が多い時期である7月と日射量が少ない時期である12月に適用させたときの平均デューティ比と、3～8月、9～2月の日射量データで学習した2つのQテーブルを日射量が多い7月又は日射量が少ない12月に合わせて適切な学習結果を適用させたときの平均デューティ比の結果を図4.13に示す。




図 4.13: 平均デューティ比

図4.13より、日射量が多い時期である7月では、平均デューティ比は1～12月の学習結果を適用させるよりも、3～8月の学習結果を適用させた方が高くなって

いることがわかる．これより，余剰な発電エネルギーの廃棄をわずかながら防ぐことができていることがわかる．また，日射量が少ない時期である 12 月では，平均デューティ比が少し下がっていることが分かる．これは図 4.11，図 4.12 で示したようにバッテリー残量を十分に保つためにデューティ比を下げているためであると考えられる．以上より，日射量が多い時期にバッテリー残量が 100 % に達し，エネルギーが余剰になることを少しでも防ぎ，センサノードの性能を高めるためには，時期に合わせた日射量データを適用させることが有用であると考えられる．また，日射量が少ない時期においても，センサノードの性能を下げつつも安定した駆動を目指すためには，時期に合わせた日射量データを適用させることが有用であると考えられる．

5 まとめ

本研究では，Q 学習を用いて，環境エネルギーで駆動するセンサノードについて，太陽光発電を利用した場合の電力制御シミュレーションを行った．評価結果では，学習に用いるデータ数の違いや，行動選択手法の違いによるシミュレーション結果の変化を確認することができた．また，未来の日射量データを予測し利用することで，より安定したバッテリー運用が見込めることを示した．また，学習データの日射量への適応性を確認し，時期に合わせた学習データを適用させることが有用であることを示した．

今後の課題としては，日射量が多い時期において，余剰エネルギーを廃棄していたことと，本研究で用いた報酬関数はバッテリー残量に依存するものであったことをうけて，報酬関数に新たにデューティ比の項を付け加えることが挙げられる．また，センサノードの用途に合わせたモデル化，太陽光以外の環境エネルギーを利用した場合のシミュレーションなどを行うことで，より現実的な環境設定下での環境エネルギー駆動型センサノードの電力制御のシミュレーションを行いたいと考えている．

参考文献

- [1] Aman Kansal, Jason Hsu, Sadaf Zahedi, Mani B. Srivastava: Power management in energy harvesting sensor networks, ACM TECS-Special Section LCTES'05 Volume 6 Issue 4 Article No.32, September 2007
- [2] 川嶋 和子, 二川 雅登, 番 喜宏, 浅野 義行, 澤田 和明, 「挿入型農業用センサを利用したトマト培地の EC 測定」, 電気学会論文誌 E (センサ・マイクロマシン部門誌), 2011
- [3] シュレスタマリ ソリット, 近藤 正章, 中村 宏, 「強化学習を用いた環境発電駆動センサノードの適応的電力制御手法の検討」, 情報処理学会研究報告, 2017
- [4] '過去の気象データ', 気象庁, <http://www.data.jma.go.jp/gmd/risk/obsdl/index.php>, (参照 2018-06-15)